

Racional estatístico

Dos espaços químicos

Mol.Sim Batch · Mol.Sim Par a Par · Nitro.RA

Documento técnico de abordagem e interpretação

PharmaSci · versão revisada · 04 de setembro de 2026

Sumário

1	Objetivo e escopo	1
1.1	Protocolo de avaliação estatística	1
2	Visão comparativa das três abordagens	2
2.1	Vocabulário comum	2
3	Mol.Sim Batch — espaço do lote do usuário	2
3.1	Escopo e entrada	2
3.2	Padronização dos descritores	3
3.3	Distância multimodal e seleção	3
3.4	Projeção MDS e interpretação	3
3.4.1	O que significam os valores do gráfico	3
3.4.2	Como interpretar o stress	4
4	Mol.Sim Par a Par — comparação estrutural direta	5
4.1	Escopo independente	5
4.2	Morgan2 e Tanimoto	5
4.3	Heatmap e mapa de contribuição	5
5	Nitro.RA — dois espaços químicos independentes	6
6	Nitro.RA PubChem — lote relativo recuperado	6
6.1	Consulta e filtros	6
6.2	Perfil estatístico relativo	6
6.3	Limitações	6
7	Nitro.RA EMA — perfil fixo do Apêndice I	7
7.1	Construção da biblioteca	7
7.2	Perfil z-score versionado	7
7.3	Parâmetros do perfil EMA atualmente instalado	7
7.4	Projeção e interpretação	7
8	Comparação final e limitações	8
9	Referências	8
10	Resumo operacional	8

1 Objetivo e escopo

Este documento descreve o racional estatístico atualmente adotado para as três formas de exploração de espaço químico disponíveis no PharmaSci: o mapa multimodal do **Mol.Sim Batch**, a comparação estrutural **Par a Par** e os mapas relativos do **Nitro.RA**. O objetivo é registrar, de forma auditável, quais dados entram em cada abordagem, como as distâncias são construídas, qual algoritmo de projeção é utilizado e quais interpretações não devem ser feitas.

A expressão “espaço químico” não representa uma única análise no aplicativo. O **Batch** e os espaços PubChem/EMA do **Nitro.RA** geram mapas 2D por MDS clássico sobre uma matriz de distância global. O **Par a Par** não gera um MDS: ele apresenta uma matriz/heatmap de similaridade estrutural entre duas moléculas, usando Morgan2 e Tanimoto. Essa distinção é central para evitar que uma métrica de um módulo seja atribuída a outro.

Regra de separação científica. O Batch representa relações dentro do lote fornecido pelo usuário; o Par a Par representa uma comparação estrutural direta; o Nitro.RA cria dois espaços externos independentes, PubChem e EMA, com bibliotecas, perfis e interpretações próprios. Nenhum desses mapas transfere automaticamente atividade, toxicidade, AI ou equivalência regulatória.

1.1 Protocolo de avaliação estatística

A avaliação foi conduzida como uma análise determinística de distância, e não como um modelo preditivo supervisionado. O procedimento foi definido antes da interpretação visual: primeiro são validados os SMILES e os descritores; depois são calculadas as dissimilaridades estruturais e físico-químicas; em seguida as componentes são combinadas; por fim, a matriz selecionada é projetada em duas dimensões. Essa ordem evita escolher vizinhos com base apenas na aparência do gráfico.

1. **Validação e elegibilidade.** Cada molécula é convertida pelo RDKit, recebe SMILES canônico e só entra no cálculo se possuir fingerprint e os seis descritores finitos. O alvo é mantido como referência explícita.
2. **Padronização.** Os descritores são transformados em z-scores para impedir que a massa molecular, o LogP ou qualquer outra variável domine a norma apenas por sua unidade ou amplitude.
3. **Duas fontes de evidência.** A distância estrutural representa a informação do fingerprint; a distância físico-química representa a posição relativa nos seis descritores. As duas componentes permanecem observáveis separadamente.
4. **Combinação pré-especificada.** A distância global usa média quadrática ponderada, com 0,60 para estrutura e 0,40 para descritores. O peso não é ajustado depois de observar o resultado.
5. **Seleção e projeção.** Os candidatos são ordenados pela distância global em relação ao alvo; somente depois os até 10 mais próximos são projetados por MDS clássico. O stress é calculado sobre as distâncias do conjunto exibido.

O racional estatístico é, portanto, de **triagem multimodal**: ele organiza relações químicas já observadas nos dados de entrada, mas não estima causalidade, potência carcinogênica, AI ou atividade farmacológica. A diferença entre o perfil local do Batch/PubChem e o perfil fixo da EMA é uma decisão de comparabilidade: o primeiro descreve a consulta atual; o segundo permite comparar consultas dentro de uma biblioteca regulatória versionada.

2 Visão comparativa das três abordagens

A tabela resume as diferenças de entrada, métrica e saída. Ela é uma visão de arquitetura estatística, não uma tentativa de fundir os módulos em um único modelo.

Abordagem	Biblioteca / conjunto	Métrica de entrada	Saída principal
Mol.Sim Batch	Lote fornecido pelo usuário + referência	MACCS/Tanimoto no mapa; distância multimodal quadrática	MDS 2D, até 10 vizinhos e tabela de distâncias
Mol.Sim Par a Par	Duas moléculas fornecidas pelo usuário	Morgan2/Tanimoto	Heatmap de similaridade estrutural; sem MDS
Nitro.RA PubChem	Até 40 CIDs recuperados e filtrados	MACCS/Tanimoto + seis descritores	MDS relativo, até 10 candidatos e ranking
Nitro.RA EMA	Perfil fixo do Apêndice I da EMA	MACCS/Tanimoto + perfil z-score versionado	MDS relativo, até 10 referências e ranking

2.1 Vocabulário comum

A **similaridade estrutural** $S_{i,j}$ varia entre 0 e 1 quando calculada por Tanimoto em fingerprints binários. Para construir uma matriz de distâncias, o aplicativo usa a dissimilaridade estrutural:

$$d_{\text{estrutural}(i,j)} = 1 - S_{i,j}$$

Assim, similaridade 1 corresponde a distância 0, enquanto similaridade 0 corresponde a distância 1. A transformação não muda a ordenação dos pares; apenas orienta a métrica para que valores maiores representem maior afastamento.

Os seis descritores físico-químicos compartilhados pela análise multimodal são massa molecular (MW), LogP, TPSA, HBD, HBA e ligações rotacionáveis (RotB). O Par a Par é uma exceção deliberada: seu heatmap é estrutural e não incorpora esses seis descritores.

3 Mol.Sim Batch — espaço do lote do usuário

3.1 Escopo e entrada

O Batch começa com uma molécula de referência e uma lista de moléculas fornecida pelo usuário. O espaço químico só é calculado quando a opção correspondente é ativada e é independente de qualquer biblioteca PubChem ou EMA. Cada entrada válida é sanitizada pelo RDKit, recebe o fingerprint e a métrica enviados pelo endpoint — na operação atual do aplicativo, MACCS/Tanimoto — e tem seus seis descritores calculados. A função interna permanece parametrizável para testes e extensões, mas o fluxo de produção do Batch fixa MACCS/Tanimoto para manter a comparação multimodal reproduzível.

A referência é sempre incluída como primeiro ponto. Entradas inválidas ou com erro são descartadas do espaço calculado, mas continuam identificáveis no resultado geral da comparação quando aplicável.

3.2 Padronização dos descritores

Como os descritores possuem unidades e amplitudes distintas, o Batch ajusta um perfil populacional sobre a referência e o lote. A transformação é:

$$z_{i,k} = \frac{x_{i,k} - \mu_k}{\sigma_k}$$

em que μ_k e σ_k são a média e o desvio padrão populacional do descritor k . Valores ausentes são preenchidos pela mediana da coluna; quando a coluna é constante, o desvio é substituído por 1 para evitar divisão por zero. Nesse último caso, a coluna não cria separação entre as moléculas.

3.3 Distância multimodal e seleção

A distância físico-química é a norma Euclidiana dos seis deltas padronizados. Ela é normalizada pelo maior valor observado em relação à referência:

$$d_{\text{FQ}(i,j)}^* = \frac{d_{\text{FQ}(i,j)}}{\max_l d_{\text{FQ}(r,l)}}$$

A distância global é uma combinação quadrática, não uma soma linear:

$$d_{\text{global}(i,j)} = \sqrt{0.60d_{\text{estrutural}(i,j)}^2 + 0.40d_{\text{FQ}(i,j)}^{*2}}$$

A componente estrutural recebe peso 0,60 e a físico-química, 0,40. A seleção mantém a referência e até 10 moléculas com menor distância global em relação a ela. O ranking científico é, portanto, equivalente a ordenar por maior similaridade global.

3.4 Projeção MDS e interpretação

MDS significa **Multidimensional Scaling**, ou **escalonamento multidimensional**. É um procedimento de redução geométrica que recebe uma matriz de distâncias entre moléculas e procura representar essas relações em um número menor de dimensões. No PharmaSci, a entrada é a matriz completa de distâncias globais entre as estruturas selecionadas: referência–teste, teste–teste e diagonal nula. O objetivo não é criar uma nova similaridade, mas encontrar coordenadas 2D nas quais as distâncias Euclidianas se aproximem, tanto quanto possível, das distâncias calculadas antes da projeção.

A implementação utiliza MDS clássico. A matriz é duplamente centralizada:

$$B = -\frac{1}{2}JD^2J$$

em que D é a matriz de distâncias globais, D^2 representa seus elementos elevados ao quadrado e J é a matriz de centralização. Os dois maiores autovalores não negativos e seus autovetores geram as coordenadas. Quando há apenas uma direção informativa, a segunda coordenada é preenchida com zero; quando não há direção positiva, os pontos são posicionados em uma configuração degenerada. Esse comportamento é preferível a inventar variação visual que não esteja presente na matriz.

3.4.1 O que significam os valores do gráfico

Cada molécula recebe um ponto (x_i, y_i) . Esses números são **coordenadas geométricas da projeção**, não valores de MW, LogP, TPSA, similaridade ou atividade biológica. A distância entre dois pontos no gráfico é:

$$d_{2D}(i,j) = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2}$$

O objetivo é que d_{2D} seja próxima da distância global original d_{global} . Assim, pontos visualmente próximos tendem a ser moléculas próximas segundo a combinação de fingerprint e descritores; pontos afastados tendem a ser mais dissimilares nessa combinação. A explicação da proximidade deve, entretanto, ser conferida na tabela: uma distância global pode ser determinada principalmente pela estrutura, pelos descritores físico-químicos ou por ambas as componentes.

Valor apresentado	Interpretação correta	O que não significa
x e y	Posição relativa no mapa 2D	Não são eixos químicos universais
Distância global	Dissimilaridade multimodal usada para ordenar os vizinhos	Não é probabilidade, toxicidade ou AI
Distância Euclidiana no gráfico	Aproximação visual da distância global	Não substitui o valor calculado na tabela
Stress MDS	Erro relativo de preservação das distâncias na projeção	Não é desempenho toxicológico ou validade regulatória

Os eixos podem ser rotacionados, refletidos ou transladados sem alterar as relações entre moléculas. Por isso, não se deve comparar diretamente o valor de X ou Y entre dois relatórios diferentes. No **Mol.Sim Batch**, o MDS mantém a orientação resultante da decomposição da matriz; no **Nitro.RA**, o alvo é posteriormente transladado para (0, 0) para facilitar a leitura. Essa translação muda a origem visual, mas não muda nenhuma distância entre os pontos.

3.4.2 Como interpretar o stress

O **stress MDS** é calculado no aplicativo como o erro relativo entre as distâncias originais e as distâncias Euclidianas observadas no plano:

$$s_{\text{stress}} = \sqrt{\frac{\sum_{i < j} (d_{\text{global}}(i, j) - d_{2D}(i, j))^2}{\sum_{i < j} d_{\text{global}}^2(i, j)}}$$

O valor é adimensional. **Stress igual a zero** significa que a configuração 2D preservou exatamente as distâncias do conjunto exibido. Valores maiores indicam que mais informação foi perdida na redução para duas dimensões. Não existe um ponto de corte universal aplicável a cada conjunto; a interpretação deve considerar o número de moléculas, a dispersão das distâncias e o objetivo da análise. Para o PharmaSci, o stress é um diagnóstico de fidelidade geométrica da figura, não um critério para aprovar ou rejeitar uma molécula.

A seleção dos vizinhos ocorre antes do MDS. Portanto, o stress exibido descreve a qualidade da projeção do conjunto efetivamente mostrado — a referência e até 10 candidatos — e não necessariamente de toda a biblioteca PubChem ou EMA. Essa distinção é importante quando o usuário interpreta o gráfico: a projeção é uma representação visual dos candidatos selecionados, enquanto o ranking deve ser consultado na tabela de distâncias.




Fig 1 Exemplo de projeção MDS sobre uma matriz de distância global. A proximidade visual deve ser conferida junto às métricas da tabela.

4 Mol.Sim Par a Par — comparação estrutural direta

4.1 Escopo independente

O Par a Par compara duas moléculas fornecidas pelo usuário. Ele não utiliza a biblioteca PubChem, a biblioteca EMA, a seleção de vizinhos do Batch ou a distância multimodal de seis descritores. Seu objetivo é mostrar, de forma direta, quais regiões estruturais são responsáveis pela semelhança calculada.

4.2 Morgan2 e Tanimoto

O fingerprint é Morgan2, isto é, um fingerprint circular de raio 2. A similaridade é calculada por Tanimoto entre os fingerprints binários. Para bits de presença, a interpretação é:

$$T(A, B) = \frac{c}{a + b - c}$$

em que a e b são os números de bits ativos em cada molécula e c é o número de bits ativos compartilhados. A escala varia de 0, nenhuma interseção observada, a 1, fingerprints idênticos.

4.3 Heatmap e mapa de contribuição

O heatmap mostra a similaridade estrutural da comparação, enquanto o mapa molecular destaca regiões que contribuem para a comparação do fingerprint. A implementação utiliza Tanimoto explicitamente nas rotinas de similaridade do mapa. O enquadramento da estrutura é adaptativo para reduzir cortes do contorno em moléculas pequenas ou grandes.

Não há eixo MDS, stress, distância físico-química ou ranking de vizinhos no Par a Par. O valor estrutural pode ser acompanhado pelas propriedades físico-químicas exibidas no relatório, mas essas propriedades não alteram o heatmap.

5 Nitro.RA — dois espaços químicos independentes

O Nitro.RA possui dois espaços químicos que não devem ser combinados: um espaço relativo baseado em candidatos PubChem e um espaço de referência baseado no perfil fixo do Apêndice I da EMA. Ambos usam MACCS/Tanimoto e a mesma combinação multimodal de seis descritores, mas diferem na origem da biblioteca e no tratamento estatístico do perfil.

Regra do alvo. Quando o alvo já está presente em uma biblioteca, sua estrutura é removida dos candidatos por comparação de SMILES canônico. O alvo continua como referência do mapa, mas não é contado como vizinho nem incluído duas vezes no ranking ou nos cálculos comparativos.

6 Nitro.RA PubChem — lote relativo recuperado

6.1 Consulta e filtros

A busca consulta o endpoint de similaridade 2D do PubChem com até 40 CIDs. Os candidatos recuperados são convertidos pelo RDKit e filtrados pela presença do grupo N-nitroso usando o padrão SMARTS [N;X3][N;X2]=O. O próprio alvo é excluído quando seu SMILES canônico coincide com o de um candidato PubChem.

Após o filtro estrutural, são mantidas as moléculas com os seis descritores e fingerprints válidos. O candidato é ranqueado pela distância global; até 10 candidatos são exibidos. A tabela é apresentada por maior similaridade global de cima para baixo, enquanto a coluna de distância global cresce no sentido equivalente de menor para maior distância.

6.2 Perfil estatístico relativo

O perfil z-score é ajustado sobre o conjunto usado naquela análise, formado pela referência e pelos candidatos PubChem válidos. A distância físico-química é normalizada em relação ao maior valor observado contra a referência nesse conjunto. Portanto, a escala é relativa à consulta e pode mudar quando o lote recuperado ou os candidatos elegíveis mudam.

A matriz selecionada é projetada por MDS clássico após a seleção dos 10 menores valores de distância global. O alvo é transladado para coordenadas (0, 0) somente para facilitar a leitura relativa do mapa; essa translação não altera nenhuma distância entre pontos.

6.3 Limitações

PubChem é uma fonte externa sujeita a disponibilidade, cobertura e resposta da consulta. A ausência de uma estrutura no lote não prova sua ausência no universo químico. Similaridade 2D, descritores e MDS são ferramentas de triagem e não transferem automaticamente AI, cPCA ou conclusão regulatória.

7 Nitro.RA EMA — perfil fixo do Apêndice I

7.1 Construção da biblioteca

O espaço EMA usa um snapshot local do Apêndice I da EMA. O perfil contém apenas a planilha de nitrosaminas, deduplica as estruturas por SMILES canônico e calcula os seis descritores válidos. O alvo é removido da biblioteca quando já estiver listado, mas permanece como referência do mapa. O tamanho da biblioteca de origem, a versão, a data e a URL são mantidos no resultado para auditoria.

7.2 Perfil z-score versionado

Ao contrário do PubChem, o perfil EMA é pré-ajustado e fixo. A média e o desvio padrão dos seis descritores são calculados na biblioteca de referência; o divisor físico-químico é fixado pelo maior valor de distância observado no perfil. Uma nova consulta não recalibra o perfil com os candidatos exibidos.

Essa escolha melhora a comparabilidade entre consultas dentro da mesma versão da biblioteca, mas não transforma o espaço EMA em uma representação completa do universo químico. Outliers não são removidos automaticamente e a atualização do snapshot muda o perfil de forma versionada.

7.3 Parâmetros do perfil EMA atualmente instalado

O perfil versionado utilizado pelo aplicativo contém 243 estruturas únicas da planilha N-nitrosamines. A tabela registra os centros e escalas populacionais usados na transformação; ela permite reproduzir a padronização sem recalculá-la a partir dos candidatos de uma consulta.

Descritor	Centro μ	Escala σ
MW	348,519	196,712
LogP	2,417	1,941
TPSA	91,105	68,751
HBD	1,309	2,329
HBA	5,342	3,520
RotB	6,103	3,733

O divisor global físico-químico fixado no snapshot é 18.009001. A versão de referência é EMA/42261/2025 Rev.13, com atualização registrada em 24/06/2026. Esses valores são parâmetros de normalização, não limites toxicológicos e não devem ser interpretados como médias populacionais gerais fora da biblioteca EMA.

7.4 Projeção e interpretação

A referência e os candidatos EMA válidos entram na distância multimodal, o alvo é transladado para (0, 0) no mapa e até 10 menores distâncias são exibidas. A translação é feita após o MDS e altera apenas a origem visual, não as relações entre pontos. PubChem e EMA aparecem em gráficos e tabelas separados. A proximidade com uma nitrosamina do Apêndice I não atribui automaticamente ao alvo o AI, a categoria cPCA ou qualquer decisão regulatória da referência.

8 Comparação final e limitações

Dimensão	Batch	Par a Par	Nitro.RA PubChem / EMA
Projeção	MDS clássico	Nenhuma; heatmap	MDS clássico relativo
Fingerprint	MACCS/Tanimoto no mapa	Morgan2/Tanimoto	MACCS/Tanimoto
Descritores	MW, LogP, TPSA, HBD, HBA, RotB	Não entram no heatmap	Os mesmos seis descritores
Biblioteca	Lote do usuário	Duas moléculas	PubChem relativo ou EMA fixo
Exibição	Referência + até 10 vizinhos	Duas estruturas	Referência + até 10 candidatos

A maior limitação comum é que uma projeção 2D comprime relações multidimensionais. O mapa deve ser lido junto com as distâncias quantitativas e com a qualidade dos dados de entrada. Nenhuma das abordagens substitui avaliação toxicológica, confirmação analítica, modelagem mecanística ou decisão regulatória.

A distância global é uma decisão de modelo com pesos explícitos, não uma verdade universal. Os valores 0,60 e 0,40 devem ser reavaliados caso o objetivo científico, o conjunto de referência ou a política de validação mude. O mesmo vale para a escolha de fingerprint, para o limite de 10 estruturas e para a versão do perfil EMA.

9 Referências

- [1] Gower, J. C. (1966). **Some Distance Properties of Latent Root and Vector Methods Used in Multivariate Analysis**. *Biometrika*, 53(3–4), 325–338. [doi:10.2307/2333639](https://doi.org/10.2307/2333639)
- [2] R Core Team. **Classical (Metric) Multidimensional Scaling**. R Documentation. [R Documentation](#)
- [3] Bajusz, D.; Rácz, A.; Héberger, K. (2015). **Why is Tanimoto index an appropriate choice for fingerprint-based similarity calculations?** *Journal of Cheminformatics*, 7, 20. [doi:10.1186/s13321-015-0069-3](https://doi.org/10.1186/s13321-015-0069-3)
- [4] RDKit. **The RDKit Book – Molecular Fingerprints and Similarity**. [RDKit documentation](#)
- [5] PubChem. **PUG REST – Programmatic Access**. [PubChem PUG REST](#)
- [6] EMA. **Questions and answers on nitrosamine impurities in human medicinal products – Appendix I**. [EMA nitrosamine guidance](#)

10 Resumo operacional

1. Identificar o módulo: Batch, Par a Par, Nitro.RA PubChem ou Nitro.RA EMA.
2. No Batch e no Nitro.RA, calcular MW, LogP, TPSA, HBD, HBA e RotB; no Par a Par, manter o heatmap Morgan2/Tanimoto separado.
3. Padronizar os descritores com o perfil apropriado: ajustado ao conjunto no Batch/PubChem ou fixo e versionado no EMA.

4. Calcular a dissimilaridade estrutural por $1 - S$ e a distância físico-química Euclidiana dos seis descritores quando aplicável.
5. Combinar as componentes por distância quadrática com pesos 0,60 e 0,40.
6. Selecionar até 10 menores distâncias globais e aplicar MDS clássico nos espaços Batch/PubChem/EMA.
7. Interpretar o resultado como triagem quantitativa, sem transferir automaticamente atividade, toxicidade, AI ou decisão regulatória.