

Racional estatístico

Dos espaços químicos

Mol.Sim Batch · Mol.Sim Par a Par · Nitro.RA

Documento técnico de abordagem e interpretação

PharmaSci · versão revisada · 28 de agosto de 2026

Sumário

1	1. Objetivo e escopo	1
2	2. Visão comparativa das três abordagens	1
2.1	2.1 Vocabulário comum	1
3	3. Mol.Sim Batch — espaço do lote do usuário	2
3.1	3.1 Escopo e entrada	2
3.2	3.2 Padronização dos descritores	2
3.3	3.3 Distância multimodal e seleção	2
3.4	3.4 Projeção MDS e interpretação	2
4	4. Mol.Sim Par a Par — comparação estrutural direta	3
4.1	4.1 Escopo independente	3
4.2	4.2 Morgan2 e Tanimoto	3
4.3	4.3 Heatmap e mapa de contribuição	3
5	5. Nitro.RA — dois espaços químicos independentes	4
6	6. Nitro.RA PubChem — lote relativo recuperado	4
6.1	6.1 Consulta e filtros	4
6.2	6.2 Perfil estatístico relativo	4
6.3	6.3 Limitações	4
7	7. Nitro.RA EMA — perfil fixo do Apêndice I	5
7.1	7.1 Construção da biblioteca	5
7.2	7.2 Perfil z-score versionado	5
7.3	7.3 Projeção e interpretação	5
8	8. Comparação final e limitações	5
9	9. Referências	6
10	10. Apêndice. Resumo operacional	6

1 1. Objetivo e escopo

Este documento descreve o racional estatístico atualmente adotado para as três formas de exploração de espaço químico disponíveis no PharmaSci: o mapa multimodal do **Mol.Sim Batch**, a comparação estrutural **Par a Par** e os mapas relativos do **Nitro.RA**. O objetivo é registrar, de forma auditável, quais dados entram em cada abordagem, como as distâncias são construídas, qual algoritmo de projeção é utilizado e quais interpretações não devem ser feitas.

A expressão “espaço químico” não representa uma única análise no aplicativo. O **Batch** e os espaços PubChem/EMA do **Nitro.RA** geram mapas 2D por MDS clássico sobre uma matriz de distância global. O **Par a Par** não gera um MDS: ele apresenta uma matriz/heatmap de similaridade estrutural entre duas moléculas, usando Morgan2 e Tanimoto. Essa distinção é central para evitar que uma métrica de um módulo seja atribuída a outro.

Regra de separação científica. O Batch representa relações dentro do lote fornecido pelo usuário; o Par a Par representa uma comparação estrutural direta; o Nitro.RA cria dois espaços externos independentes, PubChem e EMA, com bibliotecas, perfis e interpretações próprios. Nenhum desses mapas transfere automaticamente atividade, toxicidade, AI ou equivalência regulatória.

2 2. Visão comparativa das três abordagens

A tabela resume as diferenças de entrada, métrica e saída. Ela é uma visão de arquitetura estatística, não uma tentativa de fundir os módulos em um único modelo.

Abordagem	Biblioteca / conjunto	Métrica de entrada	Saída principal
Mol.Sim Batch	Lote fornecido pelo usuário + referência	MACCS/Tanimoto no mapa; distância multimodal quadrática	MDS 2D, até 10 vizinhos e tabela de distâncias
Mol.Sim Par a Par	Duas moléculas fornecidas pelo usuário	Morgan2/Tanimoto	Heatmap de similaridade estrutural; sem MDS
Nitro.RA PubChem	Até 40 CIDs recuperados e filtrados	MACCS/Tanimoto + seis descritores	MDS relativo, até 10 candidatos e ranking
Nitro.RA EMA	Perfil fixo do Apêndice I da EMA	MACCS/Tanimoto + perfil z-score versionado	MDS relativo, até 10 referências e ranking

2.1 2.1 Vocabulário comum

A **similaridade estrutural** $S_{i,j}$ varia entre 0 e 1 quando calculada por Tanimoto em fingerprints binários. Para construir uma matriz de distâncias, o aplicativo usa a dissimilaridade estrutural:

$$d_{\text{estrutural}(i,j)} = 1 - S_{i,j}$$

Assim, similaridade 1 corresponde a distância 0, enquanto similaridade 0 corresponde a distância 1. A transformação não muda a ordenação dos pares; apenas orienta a métrica para que valores maiores representem maior afastamento.

Os seis descritores físico-químicos compartilhados pela análise multimodal são massa molecular (MW), LogP, TPSA, HBD, HBA e ligações rotacionáveis (RotB). O Par a Par é uma exceção deliberada: seu heatmap é estrutural e não incorpora esses seis descritores.

3 3. Mol.Sim Batch — espaço do lote do usuário

3.1 3.1 Escopo e entrada

O Batch começa com uma molécula de referência e uma lista de moléculas fornecida pelo usuário. O espaço químico só é calculado quando a opção correspondente é ativada e é independente de qualquer biblioteca PubChem ou EMA. Cada entrada válida é sanitizada pelo RDKit, recebe o fingerprint selecionado para o mapa — atualmente MACCS/Tanimoto na chamada do endpoint — e tem seus seis descritores calculados. A referência é sempre incluída como primeiro ponto. Entradas inválidas ou com erro são descartadas do espaço calculado, mas continuam identificáveis no resultado geral da comparação quando aplicável.

3.2 3.2 Padronização dos descritores

Como os descritores possuem unidades e amplitudes distintas, o Batch ajusta um perfil populacional sobre a referência e o lote. A transformação é:

$$z_{i,k} = \frac{x_{i,k} - \mu_k}{\sigma_k}$$

em que μ_k e σ_k são a média e o desvio padrão populacional do descritor k . Valores ausentes são preenchidos pela mediana da coluna; quando a coluna é constante, o desvio é substituído por 1 para evitar divisão por zero. Nesse último caso, a coluna não cria separação entre as moléculas.

3.3 3.3 Distância multimodal e seleção

A distância físico-química é a norma Euclidiana dos seis deltas padronizados. Ela é normalizada pelo maior valor observado em relação à referência:

$$d_{\text{FQ}(i,j)}^* = \frac{d_{\text{FQ}(i,j)}}{\max_l d_{\text{FQ}(r,l)}}$$

A distância global é uma combinação quadrática, não uma soma linear:

$$d_{\text{global}(i,j)} = \sqrt{0.60d_{\text{estrutural}(i,j)}^2 + 0.40d_{\text{FQ}(i,j)}^{*2}}$$

A componente estrutural recebe peso 0,60 e a físico-química, 0,40. A seleção mantém a referência e até 10 moléculas com menor distância global em relação a ela. O ranking científico é, portanto, equivalente a ordenar por maior similaridade global.

3.4 3.4 Projeção MDS e interpretação

O MDS clássico recebe a matriz completa de distâncias globais entre as estruturas selecionadas: referência–teste, teste–teste e diagonal nula. A matriz é duplamente centralizada:

$$B = -\frac{1}{2}JD^2J$$

Os dois maiores autovalores não negativos e seus autovetores geram as coordenadas 2D. O MDS é uma projeção; seus eixos não são propriedades químicas e podem ser rotacionados, refletidos ou transladados sem modificar as distâncias.

O **stress MDS** quantifica a discrepância entre as distâncias originais e as distâncias Euclidianas no plano. Valores menores indicam melhor preservação relativa das relações; o indicador não valida toxicidade, equivalência farmacológica ou relevância regulatória.




Fig. 1 Exemplo de projeção MDS sobre uma matriz de distância global. A proximidade visual deve ser conferida junto às métricas da tabela.

4.4. Mol.Sim Par a Par — comparação estrutural direta

4.4.1 Escopo independente

O Par a Par compara duas moléculas fornecidas pelo usuário. Ele não utiliza a biblioteca PubChem, a biblioteca EMA, a seleção de vizinhos do Batch ou a distância multimodal de seis descritores. Seu objetivo é mostrar, de forma direta, quais regiões estruturais são responsáveis pela semelhança calculada.

4.4.2 Morgan2 e Tanimoto

O fingerprint é Morgan2, isto é, um fingerprint circular de raio 2. A similaridade é calculada por Tanimoto entre os fingerprints binários. Para bits de presença, a interpretação é:

$$T(A, B) = \frac{c}{a + b - c}$$

em que a e b são os números de bits ativos em cada molécula e c é o número de bits ativos compartilhados. A escala varia de 0, nenhuma interseção observada, a 1, fingerprints idênticos.

4.4.3 Heatmap e mapa de contribuição

O heatmap mostra a similaridade estrutural da comparação, enquanto o mapa molecular destaca regiões que contribuem para a comparação do fingerprint. A implementação utiliza Tanimoto explicitamente

nas rotinas de similaridade do mapa. O enquadramento da estrutura é adaptativo para reduzir cortes do contorno em moléculas pequenas ou grandes.

Não há eixo MDS, stress, distância físico-química ou ranking de vizinhos no Par a Par. O valor estrutural pode ser acompanhado pelas propriedades físico-químicas exibidas no relatório, mas essas propriedades não alteram o heatmap.

5 5. Nitro.RA — dois espaços químicos independentes

O Nitro.RA possui dois espaços químicos que não devem ser combinados: um espaço relativo baseado em candidatos PubChem e um espaço de referência baseado no perfil fixo do Apêndice I da EMA. Ambos usam MACCS/Tanimoto e a mesma combinação multimodal de seis descritores, mas diferem na origem da biblioteca e no tratamento estatístico do perfil.

Regra do alvo. Quando o alvo já está presente em uma biblioteca, sua estrutura é removida dos candidatos por comparação de SMILES canônico. O alvo continua como referência do mapa, mas não é contado como vizinho nem incluído duas vezes no ranking ou nos cálculos comparativos.

6 6. Nitro.RA PubChem — lote relativo recuperado

6.1 6.1 Consulta e filtros

A busca consulta o endpoint de similaridade 2D do PubChem com até 40 CIDs. Os candidatos recuperados são convertidos pelo RDKit e filtrados pela presença do grupo N-nitroso usando o padrão SMARTS [N;X3][N;X2]=O. O próprio alvo é excluído quando seu SMILES canônico coincide com o de um candidato PubChem.

Após o filtro estrutural, são mantidas as moléculas com os seis descritores e fingerprints válidos. O candidato é ranqueado pela distância global; até 10 candidatos são exibidos. A tabela é apresentada por maior similaridade global de cima para baixo, enquanto a coluna de distância global cresce no sentido equivalente de menor para maior distância.

6.2 6.2 Perfil estatístico relativo

O perfil z-score é ajustado sobre o conjunto usado naquela análise, formado pela referência e pelos candidatos PubChem válidos. A distância físico-química é normalizada em relação ao maior valor observado contra a referência nesse conjunto. Portanto, a escala é relativa à consulta e pode mudar quando o lote recuperado ou os candidatos elegíveis mudam.

A matriz selecionada é projetada por MDS clássico após a seleção dos 10 menores valores de distância global. O alvo é transladado para coordenadas (0, 0) somente para facilitar a leitura relativa do mapa; essa translação não altera nenhuma distância entre pontos.

6.3 6.3 Limitações

PubChem é uma fonte externa sujeita a disponibilidade, cobertura e resposta da consulta. A ausência de uma estrutura no lote não prova sua ausência no universo químico. Similaridade 2D, descritores e MDS são ferramentas de triagem e não transferem automaticamente AI, cPCA ou conclusão regulatória.

7 7. Nitro.RA EMA — perfil fixo do Apêndice I

7.1 7.1 Construção da biblioteca

O espaço EMA usa um snapshot local do Apêndice I da EMA. O perfil contém apenas a planilha de nitrosaminas, deduplica as estruturas por SMILES canônico e calcula os seis descritores válidos. O alvo é removido da biblioteca quando já estiver listado, mas permanece como referência do mapa. O tamanho da biblioteca de origem, a versão, a data e a URL são mantidos no resultado para auditoria.

7.2 7.2 Perfil z-score versionado

Ao contrário do PubChem, o perfil EMA é pré-ajustado e fixo. A média e o desvio padrão dos seis descritores são calculados na biblioteca de referência; o divisor físico-químico é fixado pelo maior valor de distância observado no perfil. Uma nova consulta não recalibra o perfil com os candidatos exibidos.

Essa escolha melhora a comparabilidade entre consultas dentro da mesma versão da biblioteca, mas não transforma o espaço EMA em uma representação completa do universo químico. Outliers não são removidos automaticamente e a atualização do snapshot muda o perfil de forma versionada.

7.3 7.3 Projeção e interpretação

A referência e os candidatos EMA válidos entram na distância multimodal, o alvo é transladado para (0, 0) no mapa e até 10 menores distâncias são exibidas. PubChem e EMA aparecem em gráficos e tabelas separados. A proximidade com uma nitrosamina do Apêndice I não atribui automaticamente ao alvo o AI, a categoria cPCA ou qualquer decisão regulatória da referência.

8 8. Comparação final e limitações

Dimensão	Batch	Par a Par	Nitro.RA PubChem / EMA
Projeção	MDS clássico	Nenhuma; heatmap	MDS clássico relativo
Fingerprint	MACCS/Tanimoto no mapa	Morgan2/Tanimoto	MACCS/Tanimoto
Descritores	MW, LogP, TPSA, HBD, HBA, RotB	Não entram no heatmap	Os mesmos seis descritores
Biblioteca	Lote do usuário	Duas moléculas	PubChem relativo ou EMA fixo
Exibição	Referência + até 10 vizinhos	Duas estruturas	Referência + até 10 candidatos

A maior limitação comum é que uma projeção 2D comprime relações multidimensionais. O mapa deve ser lido junto com as distâncias quantitativas e com a qualidade dos dados de entrada. Nenhuma das abordagens substitui avaliação toxicológica, confirmação analítica, modelagem mecanística ou decisão regulatória.

A distância global é uma decisão de modelo com pesos explícitos, não uma verdade universal. Os valores 0,60 e 0,40 devem ser reavaliados caso o objetivo científico, o conjunto de referência ou a política de

validação muda. O mesmo vale para a escolha de fingerprint, para o limite de 10 estruturas e para a versão do perfil EMA.

9 9. Referências

- [1] Gower, J. C. (1966). **Some Distance Properties of Latent Root and Vector Methods Used in Multivariate Analysis**. *Biometrika*, 53(3–4), 325–338. [doi:10.2307/2333639](https://doi.org/10.2307/2333639)
- [2] R Core Team. **Classical (Metric) Multidimensional Scaling**. R Documentation. [R Documentation](#)
- [3] Bajusz, D.; Rácz, A.; Héberger, K. (2015). **Why is Tanimoto index an appropriate choice for fingerprint-based similarity calculations?** *Journal of Cheminformatics*, 7, 20. [doi:10.1186/s13321-015-0069-3](https://doi.org/10.1186/s13321-015-0069-3)
- [4] RDKit. **The RDKit Book – Molecular Fingerprints and Similarity**. [RDKit documentation](#)
- [5] PubChem. **PUG REST – Programmatic Access**. [PubChem PUG REST](#)
- [6] EMA. **Questions and answers on nitrosamine impurities in human medicinal products – Appendix I**. [EMA nitrosamine guidance](#)

10 Apêndice. Resumo operacional

1. Identificar o módulo: Batch, Par a Par, Nitro.RA PubChem ou Nitro.RA EMA.
2. No Batch e no Nitro.RA, calcular MW, LogP, TPSA, HBD, HBA e RotB; no Par a Par, manter o heatmap Morgan2/Tanimoto separado.
3. Padronizar os descritores com o perfil apropriado: ajustado ao conjunto no Batch/PubChem ou fixo e versionado no EMA.
4. Calcular a dissimilaridade estrutural por $1 - S$ e a distância físico-química Euclidiana dos seis descritores quando aplicável.
5. Combinar as componentes por distância quadrática com pesos 0,60 e 0,40.
6. Selecionar até 10 menores distâncias globais e aplicar MDS clássico nos espaços Batch/PubChem/EMA.
7. Interpretar o resultado como triagem quantitativa, sem transferir automaticamente atividade, toxicidade, AI ou decisão regulatória.