

Racional estatístico do espaço químico 2D

Mol.Sim — comparação molecular em lote

Manus AI • 25 de agosto de 2026

Sumário

1	Objetivo e escopo	1
2	Padronização dos descritores por Z-score	1
3	Distância físico-química	1
4	Similaridade, dissimilaridade e distância global	2
5	Como funciona o MDS	2
6	Racional estatístico e limitações	3
7	Referências	4
8	Apêndice: resumo operacional	4

1 Objetivo e escopo

Este documento registra o racional estatístico utilizado pelo módulo **Mol.Sim** para construir um espaço químico bidimensional a partir de uma comparação molecular em lote. O objetivo não é produzir uma classificação farmacológica automática, mas oferecer uma representação auditável da proximidade estrutural e físico-química entre a molécula de referência e as moléculas testadas.

A análise combina duas fontes de informação. A primeira é a similaridade estrutural calculada sobre fingerprints moleculares. A segunda é a distância entre descritores físico-químicos padronizados. A combinação atualmente adotada no aplicativo é de 60% para a componente estrutural e 40% para a componente físico-química.

2 Padronização dos descritores por Z-score

Os descritores apresentam escalas e unidades diferentes. Massa molecular, LogP, TPSA, HBD, HBA e RotB não podem ser combinados diretamente sem padronização, pois uma variável com maior amplitude numérica dominaria a distância. Por isso, cada descritor é convertido em Z-score usando a média e o desvio padrão populacional calculados sobre o conjunto formado pela referência e pelo lote.

A transformação aplicada a um valor x_i é:

$$z_i = \frac{x_i - \mu}{\sigma}$$

em que μ é a média do descritor no conjunto analisado e σ é o desvio padrão populacional. O uso do desvio populacional corresponde a considerar o lote fornecido para aquela análise como o universo de comparação, e não como uma amostra destinada a estimar uma população externa.

Quando um descritor não está disponível, o valor ausente é substituído pela mediana observada para aquele descritor no conjunto. Quando os valores são constantes, o desvio padrão é substituído por 1 apenas para evitar divisão por zero; nessa situação, a coluna não gera diferença entre as moléculas.

Descritor	Unidade/ forma	Uso no modelo
Massa molecular	g/mol	Z-score
LogP	adimensional	Z-score
TPSA	Å ²	Z-score
HBD e HBA	contagem	Z-score
RotB	contagem	Z-score; inclui ligações rotacionáveis

3 Distância físico-química

Para cada par de moléculas i e j , calcula-se a diferença entre os Z-scores correspondentes. Como a planilha utiliza variações absolutas, a implementação usa diferenças absolutas antes da agregação. A distância físico-química é a norma Euclidiana desses seis deltas:

$$d_{\text{FQ}(i,j)} = \sqrt{\sum_{k=1}^6 (z_{i,k} - z_{j,k})^2}$$

Os seis descritores são MM, LogP, TPSA, HBD, HBA e RotB. Portanto, d_{FQ} é sempre maior ou igual a zero. Em seguida, a distância é normalizada pelo maior valor da distância físico-química em relação à referência no lote:

$$d_{\text{FQ}(i,j)}^* = \frac{d_{\text{FQ}(i,j)}}{\max_l d_{\text{FQ}(r,l)}}, \quad 0 \leq d_{\text{FQ}}^* \leq 1$$

A normalização coloca a componente físico-química em uma escala comparável à distância estrutural, que também varia entre zero e um para fingerprints binários.

4 Similaridade, dissimilaridade e distância global

O fingerprint produz uma **similaridade**: quanto maior o valor, mais características moleculares são compartilhadas. Para construir uma matriz de distâncias, o aplicativo converte essa medida em dissimilaridade por complemento:

$$d_{\text{estrutural}(i,j)} = 1 - S_{i,j}$$

Assim, similaridade 1 corresponde a distância 0, enquanto similaridade 0 corresponde a distância 1. Essa transformação não muda a ordenação dos pares; apenas inverte a orientação para que valores maiores signifiquem maior afastamento.

A distância global utilizada pelo espaço químico é:

$$d_{\text{global}(i,j)} = 0.60d_{\text{estrutural}(i,j)} + 0.40d_{\text{FQ}(i,j)}^*$$

A escolha da dissimilaridade, em vez da similaridade, é necessária porque o MDS recebe uma matriz de dissimilaridades/distâncias e procura pontos cujas distâncias geométricas reproduzam essa matriz. Se a similaridade fosse fornecida diretamente, moléculas muito parecidas seriam tratadas como geometricamente afastadas, invertendo o significado do mapa. A similaridade original continua preservada nos resultados, tooltips e tabelas; somente o insumo da projeção é convertido para distância.

Métrica	Faixa típica	Interpretação
Similaridade	0–1	1 = mais semelhante
Dissimilaridade estrutural	0–1	0 = mais semelhante; 1 = mais distante
Dist.FQ normalizada	0–1	0 = mesmas propriedades no modelo
Distância global	0–1	0 = maior proximidade composta

5 Como funciona o MDS

MDS significa **Multidimensional Scaling**, ou escala multidimensional. É uma técnica de ordenação que recebe uma matriz de dissimilaridades e procura representar seus objetos em um espaço com menos dimensões. Neste caso, a matriz é convertida em duas coordenadas para formar o gráfico X/Y.

A entrada do MDS não é a tabela de similaridades isoladas em relação à referência. É a matriz completa de distâncias globais entre os pares do conjunto: referência–teste, teste–teste e referência–referência. Essa característica permite que o mapa represente também a organização interna do lote.

No MDS clássico, a matriz de distâncias D é elevada ao quadrado e duplamente centralizada para produzir uma matriz de produtos escalares:

$$B = -\frac{1}{2}JD^2J$$

A decomposição espectral de B fornece autovalores e autovetores. Os dois maiores autovalores não negativos são usados para construir as coordenadas:

$$X_{2D} = V_{2D}\sqrt{\Lambda_{2D}}$$

O resultado é um conjunto de pontos cuja distância Euclidiana tenta reproduzir as dissimilaridades originais. Como a representação é bidimensional, pode haver alguma distorção quando muitas relações não cabem exatamente em um plano. O gráfico deve, portanto, ser interpretado junto com as métricas quantitativas.

Os eixos são coordenadas matemáticas, não propriedades químicas. Podem assumir valores positivos ou negativos, e a orientação pode ser refletida ou rotacionada sem alterar as distâncias. O sinal de X ou Y não significa similaridade positiva/negativa, nem atividade biológica maior/menor.




Fig 1 Exemplo do espaço químico 2D. O gráfico é uma projeção MDS sobre a matriz de distância global; os valores G correspondem à distância global em relação à referência.

Como ler o gráfico: pontos próximos representam moléculas próximas segundo a combinação definida de estrutura e propriedades. A referência é destacada em laranja; as moléculas comparadoras aparecem em azul. As coordenadas MDS podem ser negativas, mas as métricas de similaridade e distância mostradas nos rótulos/tabelas permanecem nas suas escalas próprias.

6 Racional estatístico e limitações

O procedimento de Z-score reduz o efeito das unidades e das diferenças de escala entre os descritores, mas a média e o desvio padrão dependem do conjunto analisado. Por isso, a posição de uma molécula pode mudar quando o lote é alterado. A inclusão de RotB é deliberada: o número de ligações rotacionáveis

captura uma dimensão de flexibilidade conformacional simples, complementar à informação de fingerprint e aos descritores de polaridade, tamanho e lipofilicidade.

A combinação 60:40 é uma decisão explícita do modelo. Ela dá maior influência à estrutura, mas permite que diferenças físico-químicas alterem a distância final. A escolha não deve ser interpretada como uma validação universal desses pesos; idealmente, eles devem ser avaliados em um conjunto de referência adequado ao objetivo regulatório ou toxicológico específico.

O MDS é uma ferramenta exploratória e de triagem. Proximidade no plano não constitui prova de equivalência farmacológica, toxicológica ou regulatória. A interpretação deve considerar a estrutura molecular, a qualidade dos fingerprints, as propriedades calculadas, as incertezas dos descritores e as evidências experimentais disponíveis.

7 Referências

- [1] Gower, J. C. (1966). **Some Distance Properties of Latent Root and Vector Methods Used in Multivariate Analysis**. *Biometrika*, 53(3–4), 325–338. [doi:10.2307/2333639](https://doi.org/10.2307/2333639)
- [2] R Core Team. **Classical (Metric) Multidimensional Scaling**. R Documentation, função `cmdscale`. A documentação descreve MDS clássico como uma representação de dissimilaridades por pontos cujas distâncias são aproximadamente iguais às dissimilaridades de entrada e destaca a indeterminação por translação, rotação e reflexão. [R Documentation](#)
- [3] Bajusz, D.; Rácz, A.; Héberger, K. (2015). **Why is Tanimoto index an appropriate choice for fingerprint-based similarity calculations?** *Journal of Cheminformatics*, 7, 20. [doi:10.1186/s13321-015-0069-3](https://doi.org/10.1186/s13321-015-0069-3)
- [4] Andrade, C. (2021). **Z-Scores, Standard Scores, and Composite Test Scores**. *Indian Journal of Psychological Medicine*, 43(5), 451–453. [PMC8826187](https://pubmed.ncbi.nlm.nih.gov/38826187/)

8 Apêndice: resumo operacional

1. Calcular os descritores MM, LogP, TPSA, HBD, HBA e RotB para a referência e o lote.
2. Substituir ausências pela mediana do descritor e calcular Z-scores com média e desvio padrão populacional.
3. Calcular a similaridade de fingerprint e convertê-la em dissimilaridade por $1 - S$.
4. Calcular a Dist.FQ Euclidiana e normalizá-la em relação ao maior valor observado contra a referência.
5. Combinar as componentes com pesos 0,60 e 0,40.
6. Aplicar MDS clássico à matriz completa de distâncias globais e representar os dois primeiros eixos.